Detecção Automática de Comentários Ofensivos em Português com TF-IDF e BERTimbau

Camila Menezes, Camilla Veloso e Pietra Bezerra
Disciplina de Inteligência Artificial
Professor Marcos Vinícius Silva Bento

Resumo—Este trabalho compara TF-IDF com Regressão Logística e BERTimbau na classificação binária de comentários ofensivos em português brasileiro. Utilizou-se o HateBR, com 7.000 comentários, divididos de forma estratificada em 5.600 exemplos de treino e 1.400 de teste, com semente 42. O baseline empregou unigramas e bigramas; o BERTimbau foi ajustado por três épocas, com taxa de aprendizado de 2e-5, lote de 16 e limite de 128 tokens. O baseline alcançou F1 macro de 0,8278 e acurácia de 82,79%; o BERTimbau obteve 0,9178 e 91,79%, respectivamente. O ganho foi de aproximadamente 9,00 pontos percentuais de F1 macro, com redução de 241 para 115 erros. A análise qualitativa examinou 40 erros de cada modelo, totalizando 80 registros e 77 comentários distintos, com auxílio de inteligência artificial e revisão humana. Os exemplos evidenciam dificuldades envolvendo crítica política, ironia, desqualificação indireta e contexto ausente. O BERTimbau apresentou melhor desempenho nesta execução, mas os resultados não estabelecem superioridade geral nem equivalência entre as medições de custo computacional.

Palavras-chave—processamento de linguagem natural; linguagem ofensiva; HateBR; TF-IDF; BERTimbau.

I. INTRODUÇÃO

A identificação de comentários ofensivos em redes sociais envolve tanto o volume de publicações quanto a interpretação de sua linguagem. Insultos diretos podem coexistir com ironia, abreviações, emojis e referências políticas. Além disso, uma manifestação de indignação ou uma crítica a uma política pública não deve ser automaticamente confundida com ataque pessoal ou discriminação.

O problema de pesquisa consiste em investigar como a inteligência artificial pode classificar comentários em português como ofensivos ou não ofensivos, considerando essas particularidades. Para isso, comparamos uma abordagem clássica, formada por TF-IDF e Regressão Logística, com um modelo de linguagem pré-treinado em português, o BERTimbau. A classificação utiliza os rótulos do corpus como referência de avaliação; não pretende produzir uma qualificação jurídica de cada manifestação.

A pesquisa busca responder cinco questões: se a classificação apresenta desempenho útil no conjunto analisado; qual o resultado do baseline; se o BERTimbau obtém desempenho superior no mesmo teste; quais fenômenos aparecem nos erros; e como o ganho observado se relaciona ao custo de execução. Não foi fixado previamente um limiar de desempenho satisfatório para uso real. A expectativa de maior F1 para o BERTimbau é discutida como comparação investigada, sem alegar registro prévio de uma hipótese formal.

II. FUNDAMENTAÇÃO TEÓRICA

A representação TF-IDF atribui pesos aos termos a partir de sua frequência nos documentos e de sua distribuição no corpus. A combinação com Regressão Logística permite aprender uma fronteira de classificação sobre esses vetores. Neste estudo, os bigramas acrescentam pares consecutivos de palavras, mas a representação não constrói uma interpretação contextual completa do comentário [1].

O BERT utiliza representações bidirecionais de linguagem que podem ser ajustadas a tarefas supervisionadas por meio de uma camada de saída [2]. O BERTimbau disponibiliza modelos pré-treinados para o português brasileiro; foi utilizada a versão Base, identificada como neuralmind/bert-base-portuguese-cased [3]. A capacidade de representar contexto linguístico motiva sua avaliação, mas não garante interpretar corretamente ironia ou informações ausentes da entrada.

O HateBR foi apresentado por Vargas et al. [4] como um corpus de comentários do Instagram, coletados em contas de políticos brasileiros e anotados por especialistas. O recurso contempla diferentes camadas de anotação. Este trabalho se restringe à camada binária de ofensividade e não treina um classificador específico de grupos de discurso de ódio.

III. METODOLOGIA

A. Dados e protocolo de avaliação

Utilizou-se o arquivo hatebr_and_rationales.csv da versão v5.0.0 disponibilizada no Zenodo [5]. O arquivo contém 7.000 registros, sendo 3.500 de cada classe. As entradas foram os textos da coluna comentario, e os alvos foram obtidos convertendo label final para inteiro: 0 representa não ofensivo e 1, ofensivo. As justificativas de anotação, ou rationales, não foram fornecidas aos modelos.

O pré-processamento comum removeu registros sem comentário ou rótulo. A divisão utilizou train_test_split com test_size=0.2, random_state=42 e stratify=df["label"]. Foram obtidos 5.600 registros de treino, com 2.800 de cada classe, e 1.400 de teste, com 700 de cada classe. Os mesmos filtros e a mesma ordem de entrada foram preservados nos dois experimentos.

O índice original do DataFrame foi mantido como id, sem reinicialização. Na comparação, foram verificados IDs únicos e igualdade dos comentários e rótulos nos 1.400 exemplos. A avaliação foi realizada em uma única divisão. Não houve validação cruzada, busca sistemática de hiperparâmetros ou seleção de checkpoint baseada no teste.

B. Modelos e configurações

O baseline foi implementado com TfidfVectorizer e LogisticRegression, do scikit-learn. A vetorização foi ajustada somente no treino, e o teste recebeu apenas a transformação aprendida. Foram utilizados lowercase=True, ngram_range=(1, 2) e min_df=2. A regressão empregou max_iter=1000, mantendo os demais parâmetros padrão da biblioteca.

O BERTimbau foi carregado com AutoModelForSequenceClassification e ajustado para duas classes. O tokenizador preservou maiúsculas, minúsculas e acentos, com padding e truncamento em 128 tokens, incluindo tokens especiais. O treinamento utilizou três épocas, taxa de aprendizado de 2e-5, lote de 16, otimizador AdamW, scheduler linear, warmup zero, weight decay zero e semente 42. A precisão foi FP32, sem fp16 ou bf16. Todos os pesos foram ajustados, e a previsão correspondeu à classe de maior escore de saída.

TABELA I
SÍNTESE DAS CONFIGURAÇÕES

Configuração	Baseline	BERTimbau
Representação	TF-IDF de unigramas e bigramas	Modelo pré-treinado em português
Treino e teste	5.600 e 1.400	5.600 e 1.400
Ajuste principal	max_iter = 1000	3 épocas e taxa 2e-5
Lote e comprimento	Não se aplica	16 e 128 tokens
Hardware registrado	Não informado	GPU Tesla T4

Fonte: elaboração própria a partir dos experimentos e arquivos de previsões.

C. Métricas e análise qualitativa

Foram calculadas precisão, revocação e F1 por classe, além de acurácia, F1 macro e matrizes de confusão. Precisão corresponde à proporção de acertos entre as previsões de uma classe; revocação corresponde à proporção dos exemplos dessa classe recuperados pelo modelo. F1 é a média harmônica entre precisão e revocação. O F1 macro é a média aritmética dos F1 das duas classes. As métricas foram calculadas com precisão completa e arredondadas apenas para apresentação.

Para a análise qualitativa, foram sorteados separadamente 40 erros de cada modelo com sample(40, random_state=42). As amostras compartilham três comentários, resultando em 77 textos distintos e 80 registros de análise. As leituras iniciais foram propostas com auxílio de IA, discutidas em oito blocos de dez e revisadas e aprovadas pela pesquisadora responsável pela consolidação. As categorias principais foram posteriormente padronizadas para contagem, preservando as justificativas e incertezas discutidas. Não houve anotação independente por duas avaliadoras nem cálculo de concordância.

Cada registro recebeu uma categoria principal exploratória, embora possa apresentar vários fenômenos. Categorias como ausência de contexto ou possível divergência de anotação descrevem limites da interpretação do erro, não propriedades causais do modelo. Os rótulos originais do corpus foram preservados. As frequências não representam estimativas da prevalência dos fenômenos em todos os erros ou em todos os comentários.

D. Ambiente e registro dos tempos

O BERTimbau foi treinado no Google Colab com GPU Tesla T4, cerca de 14,56 GiB de memória, Python 3.13.16, PyTorch 2.14.1+cu130, Transformers 4.57.1 e scikit-learn 1.6.1. O tempo de treino foi medido com sincronização da GPU antes e depois da chamada de treinamento. A tokenização foi registrada separadamente. No baseline, o hardware e as versões da execução não foram registrados; o cronômetro incluiu vetorização do treino, transformação do teste e ajuste da regressão.

IV. RESULTADOS QUANTITATIVOS

TABELA II
DESEMPENHO GERAL NO MESMO CONJUNTO DE TESTE

Modelo	Acur.	F1 macro	Certos	Erros
TF-IDF e Regressão Logística	0,8279	0,8278	1.159	241
BERTimbau	0,9179	0,9178	1.285	115

Fonte: elaboração própria a partir dos experimentos e arquivos de previsões.

O BERTimbau apresentou ganho de 9,00 pontos percentuais de F1 macro e de 9,00 pontos percentuais de acurácia. Houve 126 erros a menos no teste, correspondentes a uma redução relativa de aproximadamente 52,28% em relação aos 241 erros do baseline. Esses resultados descrevem a execução observada e não constituem teste de significância estatística.

TABELA III
PRECISÃO REVOCAÇÃO E F1 POR CLASSE

Modelo e classe	Prec.	Revoc.	F1	N
Baseline não ofensivo	0,8370	0,8143	0,8255	700
Baseline ofensivo	0,8192	0,8414	0,8302	700
BERTimbau não ofensivo	0,9034	0,9357	0,9193	700
BERTimbau ofensivo	0,9333	0,9000	0,9164	700

Fonte: elaboração própria a partir dos experimentos e arquivos de previsões.

Na classe ofensiva, o BERTimbau alcançou precisão de 93,33% e revocação de 90,00%. Isso significa que 70 dos 700 comentários ofensivos não foram identificados. Nos não ofensivos, 45 dos 700 foram classificados incorretamente como ofensivos. O baseline apresentou, respectivamente, 111 falsos negativos e 130 falsos positivos, tomando a classe ofensiva como positiva.

TABELA IV
MATRIZES DE CONFUSÃO EM CONTAGENS

Modelo e classe real	Previsto não ofensivo	Previsto ofensivo
Baseline não ofensivo	570	130
Baseline ofensivo	111	589
BERTimbau não ofensivo	655	45
BERTimbau ofensivo	70	630

Fonte: elaboração própria a partir dos experimentos e arquivos de previsões.

Os dois modelos acertaram os mesmos 1.101 comentários. Em 184 casos, apenas o baseline errou; em 58, apenas o BERTimbau errou; e em 57, ambos erraram. Portanto, o ganho agregado do BERTimbau não implica que todas as suas previsões sejam melhores: existem exemplos corretamente classificados pelo baseline que o modelo neural não resolveu.

TABELA V
TEMPOS REGISTRADOS E ESCOPO DAS MEDIÇÕES

Modelo	Tempo	Operações incluídas
Baseline	1,3 s	Vetorização do treino, transformação do teste e ajuste
BERTimbau	364,24 s	Somente treinamento
Tokenização do treino BERTimbau	0,60 s	Conversão do treino em tokens

Fonte: elaboração própria a partir dos experimentos e arquivos de previsões.

O treinamento do BERTimbau levou aproximadamente seis minutos e quatro segundos. Somando a tokenização do treino, foram 364,84 segundos. Download, carregamento e avaliação ficaram fora desse intervalo. Como os ambientes e os escopos dos cronômetros diferem, os valores não permitem calcular uma razão controlada de velocidade entre os algoritmos.

V. ANÁLISE QUALITATIVA DOS ERROS

A Tabela VI apresenta as categorias principais dos 40 erros examinados por modelo. O tamanho igual das amostras facilita a descrição, mas representa frações distintas dos erros totais: 40 de 241 no baseline e 40 de 115 no BERTimbau. Não se deve interpretar uma categoria ausente na amostra como inexistente entre os erros do modelo.

TABELA VI
CATEGORIAS EXPLORATÓRIAS NAS AMOSTRAS DE ERROS

Categoria principal	Base	BERT
Ambiguidade ou contexto insuficiente	6	6
Apelido ou hashtag depreciativa	2	1
Ataque figurado ou expressão depreciativa	1	3
Citação ou contestação de ofensa	2	0
Conteúdo discriminatório ou associação racializada	1	2
Crítica ou referência política sem insulto explícito	7	4
Desqualificação de ideia ou conduta	5	2
Hostilidade expressa por emojis ou hashtags	0	3
Hostilidade ou rejeição indireta	4	6
Insulto ou desqualificação pessoal direta	3	3
Ironia, sarcasmo ou deboche	5	5
Mensagem sem ofensa explícita	2	4
Possível divergência de anotação ou contexto ausente	1	1
Possível incitação à violência	1	0
Total	40	40

Fonte: elaboração própria a partir dos experimentos e arquivos de previsões.

No baseline, sete registros foram classificados como crítica ou referência política sem insulto explícito. Um exemplo é o pedido de informação sobre a correção da tabela do IRPF, marcado como ofensivo apesar de seu caráter de cobrança. Cinco registros envolveram desqualificação de ideia ou conduta, destacando a dificuldade de estabelecer uma fronteira uniforme entre reprovação e ofensa. No BERTimbau, também apareceram críticas políticas classificadas como ofensivas e mensagens positivas, como “Amei os doguinhos”, sem evidência textual suficiente para justificar uma interpretação hostil.

Ironia, sarcasmo ou deboche apareceram em cinco registros de cada amostra. O comentário “O nariz tah crescendo ou é impressão minha?” foi um falso negativo dos dois modelos e sugere acusação indireta de mentira por alusão a Pinóquio. O texto sobre “ser desmentida ao vivo” também foi perdido por ambos. Esses casos ilustram dificuldades compartilhadas, mas não sustentam que os modelos falhem sempre diante de ironia.

Os exemplos de hostilidade expressa por emojis ou hashtags apareceram em três registros da amostra do BERTimbau. Expressões como “Essa bancada é do” seguidas por figuras demoníacas deslocam parte do sentido depreciativo para os símbolos. Ainda assim, emojis de raiva não equivalem automaticamente a ameaça. Outros registros envolveram metáforas de doença, referências a capim, apelidos políticos e expressões como “arregar”, cuja leitura depende de convenções culturais e contexto.

Em seis registros de cada modelo, a categoria principal foi ambiguidade ou contexto insuficiente. “Onde é esse presídio?” pode ser pergunta literal ou provocação, e “Que consciência tem essa garota!” pode ser elogio ou ironia. O comentário de apoio à ministra, apesar do rótulo ofensivo, foi classificado como não ofensivo por ambos. Registramos esse último caso como possível divergência de anotação ou contexto ausente, sem alterar o alvo original nem afirmar que a anotação esteja errada.

Também foram encontrados ataques diretos não reconhecidos, como “Pois ela é uma sem vergonha”. Assim, o melhor desempenho agregado do BERTimbau não elimina erros em insultos explícitos. As categorias descrevem fenômenos observados nos textos e não demonstram o mecanismo interno responsável por cada previsão.

VI. DISCUSSÃO E LIMITAÇÕES

Os resultados respondem às perguntas de pesquisa de forma delimitada. A classificação apresentou desempenho acima de uma referência trivial de 50% de acerto no teste balanceado, mas não foi estabelecido um requisito de qualidade para moderação real. O baseline atingiu F1 macro de 0,8278, e o BERTimbau obteve resultado superior no mesmo conjunto. A análise dos erros identificou desafios interpretativos em ambos, especialmente diante de referências contextuais, crítica política e ataques indiretos.

A avaliação de custo não permite concluir que o BERTimbau seja a escolha adequada para qualquer aplicação. Seu ganho pode ser relevante quando a qualidade da classificação tem maior prioridade, enquanto o baseline oferece menor complexidade de treinamento neste experimento. Não foram medidos latência de inferência, consumo energético, custo financeiro, memória em produção

ou esforço de manutenção. A comparação de tempos também não foi realizada sob condições equivalentes.

A pesquisa se limita a uma divisão aleatória e uma execução por modelo. Não houve investigação da influência de duplicatas ou textos muito semelhantes entre treino e teste, nem separação por autor ou publicação. O domínio político restringe a generalização a outros públicos e redes. O truncamento do BERTimbau pode excluir informação de comentários longos, mas não foi medido seu efeito nos erros.

A análise qualitativa é exploratória, assistida por IA e revisada por uma pessoa, sem avaliação cega ou concordância entre anotadoras. O grupo não dispõe aqui do contexto completo das interações. Além disso, as categorias foram construídas após a observação das amostras e não formam uma taxonomia validada. Esses limites exigem cautela ao explicar os erros e ao transportar as conclusões para decisões de moderação.

VII. CONCLUSÃO

A comparação mostrou que o BERTimbau ajustado ao HateBR superou TF-IDF com Regressão Logística nesta execução: o F1 macro passou de 0,8278 para 0,9178, e os erros caíram de 241 para 115. O ganho veio acompanhado de maior tempo registrado e do uso de GPU no ajuste neural. A ausência de um benchmark controlado impede converter esses tempos em conclusão geral sobre eficiência.

A leitura dos 80 registros de erro evidenciou que ambos os modelos podem confundir crítica política com ofensa, deixar passar ataques explícitos e enfrentar incerteza quando o significado depende de contexto, sarcasmo ou referências culturais. O uso de representações contextualizadas melhorou os resultados agregados, mas não resolveu todos esses problemas. Estudos futuros podem repetir os experimentos com outras sementes, controlar o hardware, examinar possíveis sobreposições no corpus, medir inferência e adotar revisão qualitativa independente por mais de uma avaliadora.

DISPONIBILIDADE DOS MATERIAIS E TRANSPARÊNCIA

Os notebooks, previsões e registros estão no repositório https://github.com/CamiMenezes/indentificador-ofensivo. O dataset deve ser obtido na fonte indicada. O notebook de comparação mantém os identificadores originais, métricas e justificativas da revisão. Ferramentas de IA auxiliaram a implementação, a organização da análise qualitativa e a redação; as leituras dos erros foram revisadas e aprovadas pela pesquisadora responsável. As interpretações não substituem a avaliação crítica das autoras nem modificam os rótulos do corpus.

REFERÊNCIAS

[1] Scikit-learn, “Feature extraction,” documentação. [Online]. Disponível em: https://scikit-learn.org/stable/modules/feature_extraction.html. Acesso em: 13 nov. 2026.

[2] J. Devlin, M.-W. Chang, K. Lee e K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” in Proc. NAACL-HLT, 2019, pp. 4171–4186, doi: 10.18653/v1/N19-1423.

[3] NeuralMind, “BERTimbau Base,” Hugging Face. [Online]. Disponível em: https://huggingface.co/neuralmind/bert-base-portuguese-cased. Acesso em: 13 nov. 2026.

[4] F. Vargas, I. Carvalho, F. Rodrigues de Góes, T. Pardo e F. Benevenuto, “HateBR: A Large Expert Annotated Corpus of Brazilian Instagram Comments for Offensive Language and Hate Speech Detection,” in Proc. LREC, Marseille, 2022, pp. 7174–7183. [Online]. Disponível em: https://aclanthology.org/2022.lrec-1.777/.

[5] F. Vargas e I. Carvalho, “franciellevargas/HateBR: v5.0.0,” Zenodo, 2024, doi: 10.5281/zenodo.14397014.